TimePatch-SSL — Experimentos pendientes para Reviewer 3

Objetivo: Validar que las diferencias entre Standard y Hierarchical se deben a la arquitectura y no a problemas de entrenamiento, desbalance de clases, cantidad de parámetros o errores de evaluación.

PRIORIDAD CRÍTICA

1. Auditoría del AUROC anómalo (0.1049)

Configuración: Stress-Predict → WESAD, Standard encoder, ventanas de 30 s.

Actividades:

- Recuperar las predicciones originales y el checkpoint utilizado.
- Verificar que `0 = non-stress` y `1 = stress` en ambos datasets.
- Confirmar que AUROC se calculó utilizando la probabilidad de la clase stress: `softmax(logits)[:, 1]`.
- Recalcular AUROC con las probabilidades originales.
- Calcular también AUROC con las probabilidades invertidas (`1 - p`).
- Generar la curva ROC correspondiente.
- Determinar si el valor 0.1049 es correcto o proviene de un error de implementación/evaluación.
- Si se detecta un error, auditar los demás resultados calculados con el mismo procedimiento.

Entregables:

- Figura ROC original.
- Tabla con AUROC original e invertido.
- Archivo CSV con las predicciones.
- Informe breve confirmando o corrigiendo el resultado.

2. Análisis de matrices de confusión y predicción de una sola clase

Experimento 2: Stress-Predict → WESAD

Evaluar las cuatro configuraciones:

- Standard, 30 s.
- Hierarchical, 30 s.
- Standard, 60 s.
- Hierarchical, 60 s.

Experimento 1 y Experimento 4: Stress-Predict

Analizar principalmente el Standard encoder con ventanas de 30 s y 60 s. Incluir Hierarchical como referencia.

Actividades:

- Generar las matrices de confusión a partir de las predicciones originales.
- Calcular TP, TN, FP y FN.
- Reportar precision, recall, specificity y F1-score por clase.
- Calcular el porcentaje de ventanas clasificadas como stress.
- Comparar con un clasificador trivial que siempre predice stress.
- Determinar si existen modelos con colapso hacia la clase mayoritaria.
- Verificar que las métricas agregadas coincidan con las tablas del artículo.

Entregables:

- Matrices de confusión por configuración.
- Tabla de métricas por clase.
- Comparación con el baseline *Always-Stress*.
- Breve interpretación de los errores.

3. Verificación de convergencia del Standard encoder

Dataset: Stress-Predict.
Ventanas: 30 s y 60 s.
Modelos: Standard y Hierarchical.

Actividades:

- Recuperar las curvas originales de entrenamiento; si no existen, repetir el entrenamiento.
- Registrar training loss y validation loss por época.
- Registrar validation F1 y balanced accuracy por época.
- Identificar la mejor época y el checkpoint seleccionado.
- Revisar early stopping, learning rate, batch size y número de épocas.
- Verificar ausencia de NaN, divergencia o entrenamiento inestable.
- Determinar si el Standard encoder converge adecuadamente y generaliza a los participantes de validación.
- Comparar las curvas de Standard y Hierarchical bajo las mismas condiciones.

Entregables:

- Gráficos de training/validation loss.
- Gráficos de validation F1 y balanced accuracy.
- Tabla comparativa de convergencia.
- Conclusión: ¿el Standard encoder fue entrenado adecuadamente o pudo fallar por optimización?

4. Auditoría de equidad del entrenamiento y búsqueda de hiperparámetros

Modelos: Standard y Hierarchical en Stress-Predict.

Actividades:

- Verificar si ambos utilizaron los mismos splits de participantes.
- Comparar espacios de búsqueda de hiperparámetros.
- Documentar número de trials de Optuna por modelo.
- Comparar épocas máximas, early stopping, learning rate, batch size y weight decay.
- Confirmar que el criterio de selección de modelos fue equivalente.
- Comprobar que los sujetos de test nunca participaron en preprocesamiento ajustable, selección de hiperparámetros o entrenamiento.
- Si los presupuestos no fueron comparables, repetir los experimentos con un presupuesto equivalente.

Entregables:

- Tabla de hiperparámetros y presupuesto de optimización por arquitectura.
- Evidencia de los splits utilizados.
- Confirmación de comparación justa entre arquitecturas.

PRIORIDAD ALTA — NUEVOS EXPERIMENTOS

5. Capacity-Matched Ablation en Stress-Predict

Este es el nuevo experimento principal solicitado por Reviewer 3.

Dataset: Stress-Predict (35 participantes).

Protocolo: Experiment 1 — clasificación supervisada con validación Leave-One-Group-Out (LOGO) por participante.

Configuraciones:

Ventanas	Modelos
30 s	Standard, Hierarchical, Standard-Matched
60 s	Standard, Hierarchical, Standard-Matched

Actividades:

- Adaptar `ablation_matched_capacity/run_ablation.py` para Stress-Predict.
- Utilizar el mismo preprocesamiento y particiones para los tres modelos.
- Confirmar que la implementación de la ablación sea consistente con Experiment 1.
- Mantener condiciones de entrenamiento y selección comparables.
- Verificar el número de parámetros entrenables.
- Ejecutar LOGO sobre los 35 participantes para cada configuración.
- Calcular accuracy, F1-score, balanced accuracy y AUROC.
- Reportar media y desviación estándar entre participantes.
- Guardar resultados individuales por sujeto.
- Comparar Hierarchical contra Standard-Matched para determinar cuánto de la diferencia puede explicarse por la capacidad del modelo.

Importante: La auditoría actual indica diferencias de parámetros de aproximadamente 3.83% para 30 s y 4.80% para 60 s. Reportar los valores reales, sin afirmar una equivalencia inferior al 4% para ambas configuraciones.

Entregables:

- Extensión de Table 7 con resultados de Stress-Predict.
- Tabla de cantidad de parámetros por modelo.
- Resultados individuales por participante.
- Gráfico comparativo de los tres modelos.
- Conclusión sobre el efecto de la capacidad versus la arquitectura.

PRIORIDAD DE VALIDACIÓN

6. Análisis estadístico de la ablación

Usando los resultados del experimento 5:

Actividades:

- Comparar los modelos utilizando resultados emparejados por participante.

- Evaluar las diferencias Hierarchical vs. Standard-Matched y Standard vs. Hierarchical.
- Reportar diferencias de desempeño, intervalos de confianza y tamaños del efecto.
- Aplicar una prueba estadística apropiada para comparaciones pareadas.
- Corregir por comparaciones múltiples cuando corresponda.
- Determinar si la evidencia respalda una ventaja sistemática de Hierarchical.

Entregables:

- Tabla estadística de comparaciones.
- Gráfico de diferencias pareadas por participante.
- Interpretación sin atribuciones causales no demostradas.

7. Auditoría final de resultados y reproducibilidad

Actividades:

- Verificar la consistencia entre resultados experimentales, manuscrito y repositorio.
- Revisar especialmente las Tables 2, 3, 4, 6 y 7.
- Confirmar que las métricas se calculan siempre con la misma clase positiva.
- Publicar scripts para reproducir matrices de confusión, curvas ROC y curvas de aprendizaje.
- Actualizar el README y eliminar afirmaciones de causalidad que excedan la evidencia.
- Documentar dependencias, semillas, configuración, splits y comandos de ejecución.
- Preparar todas las figuras y tablas suplementarias con sus leyendas.

Entregables:

- Carpeta de resultados finales.
- Scripts de reproducción.
- Figuras para Supplementary Material.
- Tabla que relacione cada comentario del revisor con la evidencia generada.

Entrega final que necesito del equipo

1. **Resultados numéricos:** CSV con resultados por configuración y participante.
2. **Figuras:** matrices de confusión, curvas ROC, curvas de entrenamiento y comparaciones entre arquitecturas.
3. **Código:** scripts actualizados y ejecutables en GitHub.
4. **Reproducibilidad:** parámetros, semillas, splits y comandos usados.
5. **Informe:** un documento corto por comentario del revisor, indicando qué se hizo, qué se encontró y qué conclusión científica podemos defender.

Reglas para todos los experimentos:

- Mantener separaciones por participante.
- No optimizar hiperparámetros ni umbrales utilizando los datos de test.
- Utilizar el umbral original de 0.5 para auditar las métricas reportadas.
- No modificar la definición de stress y non-stress entre experimentos.
- No reemplazar resultados anteriores sin documentar el cambio y su justificación.
- No reportar que un resultado fue validado si solo se infirió a partir de métricas agregadas.

Orden recomendado: primero resolver el AUROC y el comportamiento del Standard encoder (experimentos 1–4); después ejecutar la ablación en Stress-Predict (experimentos 5–6); finalmente preparar las evidencias para la respuesta al revisor (experimento 7).